

Modelowanie

Matecytome

$$f: A^o \xrightarrow{1:1} (X^o \cup R^o)$$

gdzie  $A$  jest zbiorem nazw, cech i opisów zwierzątów lub  $(X^o \cup R^o)$

Klasyfikacja modeli matematycznych

# Klasyfikacja modeli matematycznych

1. Na zgodność wartości cech przed podjęciem decyzji:

- znane
  - nieznane
- } rozłączne

- inne osoby
- losowość (ryzyko)
- rozmyte
- niepewność (nieznany %)
- przybliżone

2. Na wpływ decyduenta

- ważne dla celu modelowania (kryteria)
- są częścią decyzji (zuniesie decyzyjne)

3. Kto decyduje

- wiele decyduentów (growe)
- jeden decydent (optymalizacyjne)

4. Gdzie wiedziać

- deterministyczne (twarde)
- probabilistyczne / losowe / stochastyczne
- rozmyte
- przybliżone
- mieszane

# Formułowanie zadania optymalizacyjnego

1. Przedstawianie opisu celi  $\hat{X}$

$X_{dec}^*$  - zmienna decyzyjna.. Jeżeli  $> 1$ , to trzeba uporządkować

$X_{kryt}^k$  - lista kryteriów. (Wartości na jakie mamy wpływ i chcemy osiągnąć)

$X_{dane}^\alpha$  - lista danych tzn. wszystkie pozostałe cedy, żelaz fizyczne możliwych wartości danej.

Przykład:

$X$  - zmienna decyzyjna (liczba miejsc rozstawienia); ich lokalizacja

$L$  - kryterium (Liczba rozstawień stoją)

$N$  - dane (liczba użytkowników)

$M$  - dane (liczba potencjalnych miejsc)

$Q_n$  - dane (liczba użytkowników z dostępu do danej sieci)

## 2. Prelisztacenie opisu zwiazkow $\overset{\circ}{R}$

A - Zbiór poprawnych wartości danych.

Definiując go zwiazkiem, quality danych  
gddie występują wyłącznie dane.

$Q(a)$  Zbiór dopuszczalnych wartości znanych

$\{Q(a)\}_{a \in A}$  decyzyjnych w przypadku wystąpienia  $a \in A$ .

$K(a, x)$  Zbiór możliwych wartości kryterium,

$\{\{K(a, x)\}_{x \in Q(a)}\}_{a \in A}$  gdy zostanie podjęta decyzja  $x$ ,

dla poprawnych wartości danych,  $a \in A$

$$F_A : \bigcup_{x \in Q(a)} K(a, x) \rightarrow \{0, 1\}$$

Funkcja oceny osiągnięcia celu,  
gdy pojawiają się możliwe kryteria.

Moga być różne dla różnych  
decydentów

## Poznajady:

1.  $X \subseteq \{1, 2, \dots, m\}$   $2D + D$  (zmienna decyzyjna + dana)

2.  $\emptyset \notin O_m \subseteq \{1, 2, N\}$  ( $m = \overline{1, m}$ ) dana

3.  $L = |X|$   $2D + k$

4.  $L \xrightarrow{x} \min 2D + k$

5.  $\bigcup_{m=1}^N O_m = \{1, 2, \dots, N\}$   $2D + D$

6.  $\bigcup_{m=1}^N O_m = \{1, 2, \dots, N\}$   $D$

$$E_a(L^*) = \begin{cases} 1 \text{ gdy } L' = \min_{x \in Q(a)} X(a, x) = \min L(x) \\ 0 \text{ w przeciwnym przypadku} \end{cases}$$

### 3. Analiza informacyjna

$a_j$  - ołama (cenna wiedza zwierząt decyzyjnych i kryterium)

$X_j$  - zbiór możliwych wartości ołamyk

Pred podjęciem decyzji, należy będzie znać

- ją Wertosć
- rozkład prawdopodobieństwa ją Wertosći
- stopień przynależności do ją Zbioru  $X_j$
- tylko taki zbiór  $A_j$ , dla którego  
 $a_j \in A_j \subseteq X_j$
- tylko przybliżenia zbioru  $A_j$

Po prowadzeniu analizy, może okazać się,

że należy zmodyfikować zbiory

$A, S(a), K(a, x)$

## 4. Sformułowanie zadania optymalizacyjnego

Dla danych  $a \in A$  wyznaczyć takie

$$x^* \in \Omega(a) \text{ aby } \forall y = K(a, x^*) : E(y) \leq 1$$

$\Omega(a)$  - zbiór rozwiązań (dopuszczalnych)

$x^*$  - rozwiązanie optymalne

## 5. Definiowanie $E_a$

Zat: im większa wartość kryteriów, tym lepiej.

Zbiór  $K(a, x)$  jest jednoelementowy

$$K(a, x) = \{K(a, x)\} = \{k\}$$

$K$ :

- liczba
- zbiór rozmiary
- wektor liczbowy
- zbiór liczbowy
- zmiana losowa
- zbiór przyblizony
- mieszane

$K$  jako liczba:

$$E_n(K^*) = \begin{cases} 1 \text{ gdy } k' = \max_{x \in \Omega(a)} K(a, x) \\ 0 \text{ w.p.p.} \end{cases}$$

Dla danych  $a \in A$  wyznaczyć talię

$$x^* \in \Omega(a), \text{ aby } K(a, x) = \max_{x \in \Omega(a)} K(a, x)$$

Zauważ, że max może być:

$\min, \sup, \inf, \Omega, K(x)$

# Wieloryterialność

$K$  - wektor liczbowy

$N$  - liczba kryteriów

$K_n = f_n(a, x) = f_n(x)$ , gdzie  $f_n : \mathcal{R}(a) \rightarrow \mathbb{R}$

W tym przypadku:

$$K(a) = \bigcup_{x \in \mathcal{R}(a)} K(a, x) =$$

$$= \{(f_1(x), f_2(x), \dots, f_n(x)) \in \mathbb{R}^N : x \in \mathcal{R}(a)\} =$$

$$= F(\mathcal{R}(a)) = F(\mathcal{R})$$

## Dominacja w sekwencji Pareto

Niech  $k', k'' \in F(\Omega)$

Def. Mówimy, że  $k'$  dominuje  $k''$ ,

co zapisujemy  $k' > k''$

$$\forall n = \overline{1, N} : k'_n > k''_n$$

$k''$  nazywamy elementem  
zdominowanym przez  $k'$  (relacji porządkowej)

Def. Element  $k \in F(\Omega)$  nazywany  
miedzidominowanym, jeśli

$$\exists k' \in F(\Omega) : (k' > k \wedge k' \neq k)$$

Def. Element nazywany dominującym

$$\forall k' \in F(\Omega) : k > k'$$


(element największy)

Zbiór wszystkich niezdominowanych, nazywamy zbiorem Pareto - optymalnym.

Uwaga: Zbiór elementów dominujących,  $y \in \emptyset$  to  $F'(y) \subseteq Q$  jest zbiorem rozwiązań optymalnych.

Def. Niech  $Y \subseteq F(Q)$  będzie zbiorem pareto-optymalnych. Zbiór  $F'(Y) \subseteq Q$  nazywamy zbiorem rozwiązań sprawnego.

$$E_Q(k') = \begin{cases} 1 & \text{gdy } k' \in Y \\ 0 & \text{w przeciwnym}\end{cases}$$



$k_2$




$k^*$  - zbiór pareto -  
optymalny

element dominujący


zbiór  
elementów  
zdominowanych

$K_1$



Brak elementu  
dominującego

zbiór pareto -  
optymalny




Brak elementu  
dominującego

Brak elementów  
zdominowanych

Osiąganie punktu

z pareto-optimalne



# Ponadmięk Lekcyjny

$k_1$  - najważniejsze,  $k_2$  - kolejne ...

Rozpatruje się doryg zadanie wyznaczenia obiorów

$$F_n = \left( k' \in F_{n-1} : k'_n = \max_{k \in P_{n-1}} k_n \right)$$


ogółem  $F_\Omega = F(\Omega)$

Zadanie rozwiązywamy dla kolejnych n  
rozpozynając od 1 aż dojdziemy do N-1.

$F_n$  jest zatem jednoelementowym istradą

$$F_n = F_{n+1} = \dots = F_{N-1}$$

$$E_n(k') = \begin{cases} 1 & \text{gdy } k_n = \overline{k}_N : k'_n = \max_{k \in F_{n-1}} \\ 0 & \end{cases}$$



## Metoda kompromisu (wazoniq' somy)


Jedna z metod  $F(\lambda) \rightarrow R$

$$(\lambda_1, \lambda_2, \dots, \lambda_n) \rightarrow \sum_{n=1}^N \lambda_n - k_n$$

golzie  $\lambda_n > 0$  - Subiektywne wag'i kryt.  
( $n = \overline{1, N}$ )

Wag'i zwormalizowane  $\sum_{n=1}^N \lambda_n = 1$   
(kryt. Ekonomiczne)

$$E_n(k^*) = \begin{cases} 1 & \text{gdy } \sum_{n=1}^N \lambda_n - k_n^* = \max \sum_{n=1}^N \lambda_n - k_n \\ 0 & \text{w.p.p.} \end{cases}$$



punkt optymalny  
(suma ciągosci)

o ile  $\lambda_1, \lambda_2 = 1, 1$   
 $(x) (u)$

# Metoda Punktu Ideального

$K^{\max} = (k_1^{\max}, k_2^{\max}, \dots)$  - punkt idealny

wartość każdego z kryteriów jest nawiązana.

$|k|$  - norma wektora  $k$ .

Należy wyznaczyć:

$$|K^{\max} - k'| = \min_{k \in S^2} |K^{\max} - k|$$

Czyli

$$k_u = \begin{cases} p_1 & j \cdot \omega \\ 0 & w \cdot p \cdot p \end{cases}$$

Najczęściej stosowane normy  $|k|$

1. norma z parametrem  $p \geq 1$ .

$$|k| = \left( \sum_{n=1}^N |k_n|^p \right)^{\frac{1}{p}}$$

2. norma maksymalna

$$|k| = \max_{n=1, N} |k_n|$$

3. norma euklidesowa

$$|k| = \sqrt{\sum_{n=1}^N |k_n|^2}$$

4. norma ulicna

$$|k| = \sum_{n=1}^N |k_n|$$

# Metoda punktu nadir

nadir - preciwosć zeru



$$k^{\min} = (k_1^{\min}, k_2^{\min}, \dots) - \text{punkt nadir}$$

$$\|k^{\min} - k'\| = \max_{k \in F(S)} \|k^{\min} - k\|$$

$$E_n(k') = \begin{cases} 1 & \text{i. w} \\ 0 & \text{w.p.p} \end{cases}$$

Metoda pkt. idealnego

Metoda nadir



## Programowanie celowe

Cel:  $C = \langle c_1, c_2, \dots, c_n \rangle$

Im bliżej celu, tym lepiej

$$|K - C| = \sum_{n=1}^N w_n - |x_n - k_n - c_n|$$

Jeśli  $F(g)$  jest zbiorem linijkowym  
wyplotowanym, to powyższe stwierdzenie  
sprawdzi się do 1PM.

$$c_n = \max(O_x |x_n - k_n - c_n|)$$

$$x_n = \max(O_x (c_n - x_n \cdot k_n))$$

$$c_n = x_n \cdot k_n - q_n + z_n$$

LPM - liniowe programowanie  
matematyczne

Zesumiana Zdecena w liniowym,  
w Zdecenie Liniowe

# Modele Grawe (Strategiczne)

Uwzględniamy:

- listę uczestników gry
- opisy działań możliwych
- analiza poziomu informacji jego graczy
- opis przebiegu gry
- preferencje graczy dotyczące możliwych wydarzeń

Podstawowe modele:

- a) postać elastyczna (rozwiązana)
- b) postać normalna
- c) postać funkcji: charakterystycznej.

Podaj ekstensywną grę

$N$  - liczba graczy  $n \in \overline{1, N}$

$W$  - liczba stanów gry

$V \subseteq W \times W$  - liczba możliwych przejść między stanami

$A$  - zbiór możliwych wyborów graczy.

Def. Gra  $N$ -osobowa w postaci ekstensywnej

$$G = (W, U)$$

1) Surjekcja  $f: U \rightarrow A$

2) Podzielić zbiór  $W$  na podzbiory

a) zbiór stanów losowych  $W_0$

b)  $\{W_{nk}\}_{k \in K_n}$  - rodzina zbiorów informacyjnych gracza nr  $n$ ,  $K_n$  - zbiór indeksów

$W_n = \bigcup_{k \in K_n} W_{nk}$  - zbiór stanów gry, w których decyzja należy do gracza  $n$

c) zbiór stanów koncowych gry

Dla każdego ze stanów losowych  $\omega \in \Omega_0$  -

rozkład prawdopodobieństwa na zbiore zdarzeń

$$A(x) = \{ f(x, y) \in A : y \in \Gamma(x) \}$$

h) funkcje wewnętrzowe  $U: \Omega^k \rightarrow \mathbb{R}^N$

$$U(x) = (u_1(x), u_2(x), \dots, u_n(x))$$

$u_n(x)$  - wynata (uzycieczność) dla

gracza nr  $n$ , gdy osiągnie stan  
monitowy  $x \in \Omega^k$

Miążące właściwości:

$$\text{I) } x', x'' \in \Omega^k \Rightarrow (|r(x')| = |r(x') \cap f(U(x'))| = \\ = f(U(x''))) )$$

$$\text{gotówka: } U(x) = \{ \langle x, y \rangle \in U : y \in \Gamma(x) \}$$

II) W każdej drodze Toczącej koni  
ożewa  $G = (\Omega, U)$  z wiechotliwem (partition)  $\Sigma$   
występuje co najmniej jeden wiechotlikiego  
zbioru informacyjnego.


$N = 3$

$n = 2$  - producent

$n = 1$  - dziekan

$n = 3$  - student

$A = \{DT, DP, PT, PN, U, N, O, R\}$



Def: Strategią gracza nr  $n$  nazywamy

funkcję  $s_n : K_n \rightarrow A$  o właściwości:

$$(s_n(u) = a) \Rightarrow \exists (x, y) \in U : (f(x, y) = a \wedge x \in h_n)$$

co by zrobić, gdyby doszło do konieczności podjęcia decyzji, nie wiedząc jaka będzie stan poprzedni.

$S_n$  - zbiór strategii czystych gracza nr  $n$

Def. Profilem strategii czystych nazywamy

element zbioru:  $S = \prod_{n=1}^N S_n$ , czyli wektor

$$S = \langle s_1, s_2, \dots, s_n \rangle$$

$$S_1 = \{ \{ \langle 1, DT \rangle \}, \{ \langle 1, OP \rangle \} \}$$

$$S_2 = \{ \{ \langle 1, PT \rangle \}, \{ \langle 1, PN \rangle \} \}$$

$$S_3 = \{ \{ \langle 1, V \rangle, \langle 2, V \rangle \}, \{ \langle 1, V \rangle, \langle 2, N \rangle \}, \{ \langle 1, N \rangle, \langle 2, N \rangle \} \}$$

Strategie czyste  $\uparrow$

krótsze zapisy

$\langle DT_1, PN, \langle v, w \rangle \rangle, \langle DT_1, PN, UN \rangle$

1. Każdemu profilowi strategii i czystych  
odpowiada dokładnie jedna partia

2. W przypadku No 1 przyjmujemy wartości  
oczekiwanej

strat	grac	wynik
$\langle DP, PT, UN \rangle$	$\langle 1, 3, 6, 10 \rangle$	$\langle 0, 1, 1 \rangle$
$\langle DT_1, PT, NN \rangle$	$\langle 1, 2, 5, 8 \rangle$ $\langle 1, 2, 5, 9 \rangle$	$\langle 0, 0, 0 \rangle \frac{1}{2} \}$ $\langle 0, 0, -2 \rangle \frac{1}{2} \} \langle 0, 0, -1 \rangle$

Postać normalna gry

Def.:  $N$ -osobowa gra w postaci normalnej to

$$\langle S_1, S_2, S_3 \dots, S_n, u \rangle$$

gdzie  $u : \prod_{n=1}^N S_n \rightarrow \mathbb{R}^N$

.

Dylemat więźnia

$$S_1, S_2 = \{P, N\}$$

U:	2 1	P	N
P	$\langle 1, 1 \rangle$	$\langle 3, 0 \rangle$	
N	$\langle 0, 3 \rangle$	$\langle 2, 2 \rangle$	

Zmodyfikowana walka półci

$$S_1 = S_2 = \{O, K\}$$

U:	2 1	O	K
O	$\langle 2, 1 \rangle$	$\langle 0, 0 \rangle$	← modyfikacja
K	$\langle 0, 0 \rangle$	$\langle 1, 2 \rangle$	$\langle 0, 1 \rangle$ ??

Def.: Strategia mieszana gracza nr n  
nazywamy rozkładem prawdopodobieństw na  
 $S_n$ , tzn. wektor

$$P_n = \langle p_n^1, p_n^2, \dots, p_n^n \rangle$$

gdzie  $p_n \geq 0$  ( $n = \overline{1, n}$ )

$$\sum_{i=1}^n p_n^i = 1$$

$P_n$  - zbiór wszystkich strategii mieszanych  
gracza nr n

Def. Funkcja wyplatająca strategię mieszaną nazywamy funkcją i

$$u : \prod_{n=1}^N p_n \rightarrow \mathbb{R}^n$$

O wartościach  $u(p) = (u_1(p), u_2(p), \dots, u_n(p))$

gdzie  $p = (p_1, p_2, \dots, p_n)$  - profil

strategii mieszańych

$$u_n(p) = \sum_{s \in C} v(s) \cdot \prod_{n=1}^N p_n^{l_s}$$

$$S = \langle S_1^{L_1}, S_2^{L_2}, \dots, S_n^{L_n} \rangle$$

Przykład:

Dylemat więźnia

$S_1, S_2 = \{P, N\}$

		$\frac{1}{2}P + \frac{1}{2}N$
		$\frac{1}{2}P + \frac{1}{2}N$
U:		$P$
$\frac{1}{4}P$		$N$
$\frac{3}{4}N$	P	$\langle 1, 1 \rangle$
	N	$\langle 3, 0 \rangle$
$\frac{3}{4}N$	P	$\langle 0, 3 \rangle$
	N	$\langle 2, 2 \rangle$

$$d(P_1, P_2) = (2, 1)$$

Uwaga: Strategia czysta  $S_n$  może być  
zastawana jako strategia mieszana.

$$\langle P_1, \dots, P_N \rangle$$

Niech:  $P = \langle P_1, P_2, \dots, P_N \rangle$

Oznaczenia:  $\bar{P}_n = \langle P_1, \dots, P_{n-1}, P_{n+1}, \dots, P_N \rangle$

Def. Strategie czystą nazywaną złożinową  
jeśli strategia mieszana ma niepuste podzbiory  
osiągi.

$$S_1, S_2 = \{P, N\}$$

U:


	2	P	N
P	$\langle 1, 1 \rangle$	$\langle 3, 0 \rangle$	
N	$\langle 0, 3 \rangle$	$\langle 2, 2 \rangle$	

$$1 > 0, 3 > 2$$

Strategie czyste są  
zdominowane przez  
P.

Iterowana eliminacja strategii czystych

Wykresła się strategie zdominowane konstrukcyjnie  
"mniejszą grę", tak dugo jak to jest  
możliwe. Porządkując tzw. racjonalizowane.



$\mathcal{S} = \mathbb{S}$

Def. Strategie  $s_n \in \mathbb{S}$  nazywamy najlepszą odpowiadającą gracza nr.  $n$  na profil strategii  $\bar{p}_n$  pozostałymi graczami, jeśli

$$\forall s'_n \in \mathbb{S}_n : u_n(s_n, \bar{p}'_n) \geq u_n(s'_n, \bar{p}_n)$$

Def.: Profil strategii czystych  $s \in \mathbb{S}$  nazywany punktem równowagi w sensie Nasha)

jeśli:  $\forall_n = \frac{1}{N} : s_n \in \text{NO}_n(s_n)$

Tedy ponadto:

$$\forall_n = \frac{1}{N} : |\text{NO}_n(s_n)| = 1$$

$s \in \mathbb{S}$  nazywamy równowagą Nasha

Dylemat więźnia

$$S_1, S_2 = \{P, N\}$$

		2	P	N
		1		
P			$\langle 1, 1 \rangle$	$\langle 3, 0 \rangle$
N			$\langle 0, 3 \rangle$	$\langle 2, 2 \rangle$

$$N\phi_1(P) = \{P\} = N\phi_1(N)$$

$$N\phi_2(P) = \{P\} = N\phi_2(N)$$

$\{P, P\}$ -punkt równowagi w sensie Nasha

Walla P Tci

		2	0	K
		1		
0			$\langle 2, 1 \rangle$	$\langle 0, 1 \rangle$
K			$\langle 0, 0 \rangle$	$\langle 1, 2 \rangle$

$$NO_1 = \{0\} \quad NO_1(e) = \{u\}$$

$$NO_2(K) = \{0, K\}$$

$$NO(K) = \{u\}$$

Punkt równowagi w sensie Nasha  $(0, 0)$   $(K, K)$

scisła równowaga  $(e, e)$

Def.: Profil strategii mieszanego  $p \in \Phi$   
 nazywany równowagą Nasha w  
 strategiach mieszanych, jeśli

$$\forall n = \overline{1, N} \quad \forall s_n \in \mathcal{S}_n : u_n(p_n, \bar{p}_n) \geq u_n(s_n, \bar{p}_n)$$

Def.: Grę  $G^Y = \langle W^Y, \psi^Y \rangle$  nazywaną  
 podgrą gry  $G = \langle \psi, \Psi \rangle$  o  
 konenciu  $y \in \psi$ , jeśli


- 1) jest zredukowana o konenciu  
 $y \in \psi$  zawierającą wszystkie  
 wierszohoteli osiągające 2 y
- 2)  $\forall x \in \psi^Y \quad \forall n = \overline{1, N} \quad \forall k \in K_n :$

$$(x \in \psi_{nk} \Rightarrow W_{nk} \subseteq W^Y).$$

$G^Y$  jest podgrą właściwą jeśli  $G^Y \neq G$  oraz  $|\psi^Y| > 1$

Def.: Profil strategii  $p \in P$  nazywa się doskonałego równowagi Nasha w grze G, jeśli wyznacza on równowagę Nasha w każdej podgrze tej gry.

Przykład



	A'X	A'Y	B'X	B'Y
W	$\langle 2, 0 \rangle$	$\langle 1, 4 \rangle$	$\langle 2, 6 \rangle$	$\langle 2, 6 \rangle$
Z	$\langle 2, 1 \rangle$	$\langle 3, 4 \rangle$	$\langle 2, 6 \rangle$	$\langle 2, 6 \rangle$

Punkty równowagi:  
 $A'Y, W B'X, W B'Y$

równowaga doskonała:  $\langle 3, 4 \rangle$


Indukcja wstępna - kolejne wykresy

"od końca" większość, której  
ostygnąć nie jest racjonalne.

Usuwane są kolejno strategie tzw.

warunkowe i takie, gdyż  
warunkiem jest dość do  
innych gry.

Przykład:



Optymalismy:  $\langle 5, 4 \rangle$

$\langle NX, AD \rangle$ ,  $\langle NX, BD \rangle$ , ...

Def.: Frazdy m'iepesty podzbior' numerow graczy  $\psi = \{1, 2, \dots, N\}$  nazywany koalicjg.

Def.: Funkcje  $\omega: 2^\psi \rightarrow R$  przyjmowane przez kazdego  $\$ \subseteq \psi$  wartosc' maksymalna w grze dwuosobowej rozgrywanej pomiędzyc  $\$ \cap \psi \setminus \$$  nazywany funkcjg charakterystycznej gry, gdy spełnia:

$$\omega(\emptyset) = 0$$

$$\$ \cup \# \subseteq \psi \wedge \$ \cap \# = \emptyset \Rightarrow \omega(\$ \cup \#) \geq$$

$$\omega(\$) + \omega(\#)$$

Przykład: Trzech graczy stoi przed problemem utworzenia koalicji. Jeśli dwóch z nich utworzą koalicję, to trzeci gracz wypłaca po 1. Jeżeli żadna dwuosobowa koalicja nie powstaje, to wypłata nie nastąpi.

$$\omega(\$) = \begin{cases} 2 & \text{gdy } |\$| = 1 \\ 2 & \text{gdy } |\$| = 2 \\ 0 & \text{gdy } |\$| = 3 \vee |\$| = 0 \end{cases}$$

$$\langle -2, 1, 1 \rangle, \langle 1, -2, 1 \rangle, \langle 1, 1, -2 \rangle, \langle 0, 0, 0 \rangle$$

Uwaga: Wektor  $u(x) = \langle u_1(x), u_2(x), \dots, u_n(x) \rangle$   
można interpretować jako sytuację,  
w której następuje jeden decydent  
ale skutkuje decyzyjnie  $x \in U^K = \Omega$   
ocenianie...

# Modele Probabilistyczne

Podejmuwanie decyzyjne  
w warunkach ryzyka

$K$  - zmienna losowa

Zastąpienie zmiennej  $K$  kryterium liczącym

1. Wartość określana (najczęściej)

$E[K]$  - wartość określana zmiennej losowej  $K$ .

$$E_a(K^{-1}) = \begin{cases} 1 & \text{dla } E[K^*] = \max E[K] \\ 0 & \text{w.p.p.} \end{cases}$$

2. Kwantyl zmiennej losowej.

Def.: Kwantylem rzędu  $p$  ( $0 \leq p \leq 1$ )

zmiennej losowej  $X$  nazywany liczbą

$$w_p(x) = \max \{ w \in \mathbb{R} : \Pr\{X \leq w\} \leq p \}$$

$$E_a(k^*) = \begin{cases} 1 & \text{dla } w_p(k^*) = \max_{k \in \mathcal{K}(a)} p(k) \\ 0 & \text{w.p.p.} \end{cases}$$

$k^*$  - nowa dana

3. Wariancja zmiennej losowej.

$\text{Var}(k)$  - wariancja (rozrzut, dyspersja)

Zmiennej losowej  $K$ .

$$E_a(k^*) = \begin{cases} 1 & \text{dla } \text{var}(k^*) = \min_{k \in \mathcal{K}(a)} \text{var}(k) \\ 0 & \text{w.p.p.} \end{cases}$$

Bardziej "przewidywalny" skutek jest lepszy

od niekoniecznie tego, ale mniej

"przewidywalnego"

## 4. Prawdopodobieństwo zdania

a) konstnego

A - zdanie konstne

$$E_a(k^*) = \begin{cases} 1 & \text{dla } \Pr\{k^* \in A\} = \max_{k \in k(a)} \Pr\{k \in A\} \\ 0 & \text{w.p.} \end{cases}$$

b) niekonstnego

$$E_a(k^*) = \begin{cases} 1 & \text{dla } \Pr\{k^* \in B\} = \min_{k \in k(a)} \Pr\{k \in B\} \\ 0 & \text{w.p.} \end{cases}$$

Uwaga: Nie musi zachodzić  $B = \emptyset$ ,

$$\text{ale } A \cap B = \emptyset$$

5. Zasada uwzględniania miatych prawdopodobieństw w decyzyjnych jednokrotnych

K - dyskretna losowa

$$\text{Nieu} f_m = \Pr \{ K = k_m \}$$


$p^*$  - próg uwzględniania zdarzeń pomijających te zdarzenia  $k_m$  ( $m = 1, M$ )

dla których  $f_m < p^*$

Oblicza się "odpowiednie" wartości określonej.

$$R(k) = \sum_{m: f_m \geq p^*} k_m \cdot f_m$$

$$E_a(k^*) = \begin{cases} p^* & \text{dla } R(k^*) = \max_{k \in K(a)} R(k) \\ 0 & \text{w.p.p.} \end{cases}$$




$$E[K_1] = \frac{53}{10}$$

$$E[K_2] = \frac{51}{10}$$

$$k^* = k_1$$

olla  $P_0 = \frac{2}{10}$



$$R(K^*) = \frac{41}{10} \quad R(K^c) = \left(\frac{50}{10}\right)$$

$$k^* = k^c$$

Zastępowanie zmiennej losowej  $K$   
wielorem liczbowym.

$$E[K], \text{var } K, \Pr\{K \in A\}, \Pr\{K \in B\}$$

a następnie stosuje się metody  
cielokryterialne. Jednak z metod jest  
dowiązana para do dwóch kryteriów.

# Dominacja efektywności kryterium.

$K$  - dyskretna zmieniona losowa o wartościach  $k_1, k_2, k_3, \dots$ . Niech  $P_m = \Pr\{K \geq k_m\}$

Def.: Efektywność kryterium nazywa się

parę  $\{k_m, P_m\}$ .

	$P_1$	$P_2$	$P_3$	$P_n$
$k_1$	2	1	3	4
$k_2$	3	1	4	3
$k_3$	2	3	2	4

$k_1$ :

$k_2$ :  $\left\langle 3, \frac{1^3}{2^0} \right\rangle$

$k_3$ :  $\left\langle 2, 1 \right\rangle$        $\left\langle 4, \frac{1^4}{2^0} \right\rangle$

## Drzewo decyzyjne

$D = \langle \Psi, \psi \rangle = \langle \Psi, \Gamma \rangle$ , drzewo

w którym  $\Psi = \Phi \cup \mathcal{M}$  ( $\Phi \cap \mathcal{M} = \emptyset$ )

$\Phi$  - zbiór wierzchołków (stanów) decyzyjnych

$\mathcal{M}$  - zbiór wierzchołków (stanów) losowych

gddie  $\Gamma(\phi) \subseteq \mathcal{M} \wedge \Gamma(m) \subseteq \Phi \wedge r(m) \neq \phi$

dla  $\phi \in \Phi \wedge m \in \mathcal{M}$

Koniec drzewa jest wierzchołkiem


decyzyjnym oznaczającym koniec procesu podejmowania decyzji.

Określone są:

- zbiór  $A$  możliwych decyzji:
- przyproponowanie przejść do możliwych przejść decyzyjnych.  
 $f : (\Phi \times \mathbb{N}) \cap U \rightarrow A$
- rozkady prawdopodobieństwa na zbiorach zdarzeń, które mogą mieć miejsce w stanie  $m \in \mathbb{N} : Z_m = \{z_m, d\} \}_{d \in r(m)}$
- funkcje wypłat czesciowych  $k_i : W \rightarrow \mathbb{R}$

Uwaga: Wypłaty są definiowane rekurencyjnie pochodzące od listy konsystencji decyzyjnego.

Przykład:



E - 26: oś zdaniu'. Jeśli  $A, B, C \in E$  oraz

$p = [0, 1]$ , to zachodzi  $\{p \cdot A + (1-p) \cdot B\} \in E$ .

To zdanie nazywa się loterią.

W E zdefiniowana została relacja binarna

$A > B$ , oznaczająca że  $A$  lepsze

widział A od zdania B  $\neg(A > B) \wedge \neg(B > A) = A = B$

## Twierdzenie o funkcji czystocząści

Dla zbioru  $E$  i relacji  $\succ$  istnieje funkcja

$u: E \rightarrow \mathbb{R}$ , taka że:

$$1) u(A) = u(B) \Leftrightarrow A = B$$

$$2) u(p \cdot A + (1-p) \cdot B) = p \cdot u(A) +$$

$$\cdot (1-p) \cdot u(B)$$

3) jest jedyną taką funkcją z dodatniosią  
do przekształcenia liniowego.

$$E_A(A^*) = \begin{cases} 1 & \text{dla } u(A^*) = \max u(A) \\ 0 & \text{w. p. p.} \end{cases}$$

Ryzyka i uogólnione

A : 2

C > B > A

B : 1

u(A) = 0

C : 2

u(C) = 1

i ile wynosi  $u(B)$ ?

$$B = \{p \cdot A + (1-p) \cdot C\}$$

Przyjmijmy, że  $p = 0.2$  ("lepszy wybór w garsią")

duższa  $E[B] = 1$  oraz  $E[\{p \cdot A + (1-p) \cdot C\}] = 1.2$

Stąd:  $u(B) = 0.2 \cdot u(A) + 0.8 \cdot u(C) = 0.3$

A co lepsze?

$$X = \{0.1 \cdot A + 0.9 \cdot B\} \text{ czy } Y = \{0.2 \cdot A + 0.8 \cdot \\ \{0.6 \cdot B + 0.4 \cdot C\}\}$$

$$u(X) = 0.1 \cdot u(A) + 0.9 \cdot u(B) = 0.9 \cdot 0.8 = 0.72$$

$$u(Y) = 0.2 \cdot u(A) + 0.8 \cdot 0.6 \cdot u(B) + 0.8 \cdot 0.4 \cdot u(C) \\ = 0.704$$

Modele  
Rozumte

Def.: Zbiór rozumyty A w przestrzeni  $\mathbb{X}$

jest to funkcja

$$\rho: \mathbb{X} \rightarrow [0, 1]$$

Czyli:  $A = \{(x, \mu(x)): x \in \mathbb{X}\}$

Funkcja  $\mu$  funkcją przynależności  
do zbioru rozumytego A.

Funkcja przynależności oznaczany  $\mu_A$

Dla  $X = \{x_1, x_2, \dots, x_n\}$  przyjęto  
oznaczać:

$$A = \frac{\mu_A(x_1)}{x_1} + \frac{\mu_A(x_2)}{x_2} + \dots$$

$$\frac{\mu_A(x_n)}{x_n} = \sum \frac{\mu_A(x_n)}{x_n}$$

a ogólnie  $\int \frac{\mu_A(x)}{x}$

Przy powyższych zapisach pomija się to że  $x \in X$  dla których

$$\mu_A(x) = 0$$

Znacząco:

- zbiory nierozumiałe (przestrzeni):

$A$  - poprawnych wartości danych

$\Omega(A)$  - dopuszczalnych decyzji przy  
danych  $a \in A$

$K(a)$  - możliwych wartości kryterium  
przy danych  $a \in A$  - mechanizm  
realizacji decyzji nierożumiałej

$d_a : \Omega(a) \rightarrow K(a)$

-  $C_a \in F(\Omega(a))$  wybór rozumiałego  
dopuszczalnych decyzji.

$g_n \in F(K(a))$  - cel rozumiałego

Def.:  $h_n \in F(\Omega(a))$  deyuza rozmaita

$$h_n(x) = \min (c_n(x), g_n(d_n(x)))$$
$$x \in \Omega(a)$$

Nierozmyta deyuza optymalna jest to deyuza  $x^* = \Omega(a)$  dla ktorej:

$$h_n(x^*) = \min \{c_n(x^*), g_n(d_n(x^*))\} =$$
$$= \max_{x \in \Omega(a)} \min \{c_a(x), g_a(d_a(x))\}$$

Dozwolny do tego, aby deyuza optymalna  
- byla 'jal najbardziej' dopuszcana  
- 'jal najbardziej' zapewniała osiągnięcie celu

Zbiory rozmyte  $c_a$  i  $g_a$  konstruowane

Szczególnie z użyciem algebrau zbiorów rozmytych  
lub logiki rozmytej

Niech  $A, B \in F(x)$

Dopełnienie  $\bar{A}$  zbioru  $A$ :  $\mu_{\bar{A}}(x) = 1 - \mu_A(x)$

Suma  $A \cup B$ :  $\mu_{A \cup B}(x) = \max\{\mu_A(x), \mu_B(x)\}$

Suma algebraiczna:  $A + B$

$$\mu_{A+B}(x) = \mu_A(x) + \mu_B(x) - \mu_A(x)\mu_B(x)$$

Pierwiastek:  $A \cap B$ :  $\mu_{A \cap B}(x) = \min\{\mu_A(x), \mu_B(x)\}$

Moczyn algebraiczny:  $\mu_A(x) \cdot \mu_B(x)$

Moczyn skalar:  $\alpha \in [0, 1]$ :

Zbiór  $A - \alpha \cdot A$

$$\mu_{\alpha \cdot A}(x) = \alpha \cdot \mu_A(x)$$

Autounim  $A$  dla  $X = [0, N]$ :  $\mu_{\gamma_A}(x) = \mu_A(N-x)$

Iloczyn kartezjański zbiórów rozumytych

$A_i \in F(x) \quad (i = \overline{1, n})$

jest to zbiór rozumyty  $B \in F(X_1, X_2, \dots, X_n)$

Oznaczamy  $A_1 \times A_2 \times \dots \times A_n$  dla

którego

$$\mu_{A_1 \times A_2 \times \dots \times A_n}(x_1, x_2, \dots, x_n) = \min \{\mu_{A_1}(x_1), \mu_{A_2}(x_2), \dots\}$$

Relacja rozumyta  $R$  jest to zbiór rozumyty

duresłony na iloczynie kartezjańskim  $X \times Y$

$$tzn. \mu_R : X \times Y \rightarrow [0,1]$$

Przykład: komputer o częstotliwości

zegara  $x$ , co daje sygnały

od komputera o częstotliwości  $y$

$$\mu(x,y) = \begin{cases} 0 & x \in Y \\ \frac{x-y}{10^9} & y < x \leq y + 10^9 \\ 1 & \text{jeśli } x > y + 10^9 \end{cases}$$

Niech  $A, B = F(x)$

Wysokość zbioru rozumytyego  $A$

$$h(A) = \sup_{x \in X} \mu_A(x)$$

Zbiór rozumyty  $A$  jest normalny - jeśli  $h(A) = 1$

Niektóry zbiór rozumyty  $A$ :

$$\sup p(A) = \{x \in X : \mu_A(x) > 0\}$$

Zbiór rozumyty  $A$  jest pusty, jeśli

$$\sup p(A) = \emptyset$$

dziecięcoj zbiór rozmystego A

$$A_\alpha = \{x \in X : \mu_A(x) \geq \alpha\}$$

Rozmiar zbioru rozmystego A:

$$\text{core}(A) = \{x \in X : \mu_A(x) = 1\}$$


Czyli  $\text{core}(A) \subseteq A_1$

Zbiór rozmysty  $A \in F(\mathbb{R}^n)$  jest całkowity

jednimi

$$\forall x, y \in \mathbb{R}^n \forall \alpha \in [0, 1] : \mu_A(\alpha \cdot x + (1 - \alpha) \cdot y) \geq \min \{\mu_A(x), \mu_A(y)\}$$

współzbiór zbioru, niefc



## Liczby rozmyte

Niech  $x \in \mathbb{R}$


Liczba rozmyta jest to normalny, wypukły zbiór rozmyty, którego funkcja przynależności jest przedziałowa i ciągła oraz mówiąc ją jest ograniczony. Liczba rozmyta

$\mu_A(x)$  jest dodatnia jeśli:

$\mu_A(x) = 0$  dla  $x < 0$ , a jest oznacza

[czyli  $\mu_A(x) = 0$  dla  $x > 0$ ]

Najczęstsze liczby



trójkątna



trapezoidalna

# Logika rozmyta

Wartości logiczne formuły tych funkcji

Zadanie: otrzymać dla  $\neg$  nie dla  
dwóch zdań "prawda", "fałsz", ale  
"stopnie prawdy" będącego z  
przedziału  $[0,1]$

Negacja  $n: [0,1] \rightarrow [0,1]$

Prop. cechy:

$$1. n(0) = 1$$

$$2. n(1) = 0$$

$$3. x \leq y \Rightarrow n(x) \geq n(y)$$

Najczęściej:  $n(x) = 1 - x$

$t$ -norma

$$t: [0,1] \times [0,1] \rightarrow [0,1]$$

przykazy:

$$1. t(x, 1) = x$$

$$2. x \leq y \Rightarrow \forall z: t(x, y) \leq t(y, z)$$

$$3. t(x, y) = t(y, x)$$

$$4. t(x, t(y, z)) = t(t(x, y), z)$$

Najczęściej:

a) suma  $\{x, y\}$

b)  $x \cdot y$

c)  $\max \{0, x+y-1\}$

$t$ -louoma,  $\delta$ -norma


$$S: [0,1] \times [0,1] \rightarrow [0,1]$$

my seym:

$$1' S(x, 0) = x$$

fakt. j'cole taen

2, 3, 4



Naučsocič:

a)  $\max\{x, y\}$

b)  $x+y - x \cdot y$  Wurde probabilistisch

c)  $\min\{1, x+y\}$   $t$ -louoma  
siedl'cza

Implication  $i : [0,1] \times [0,1] \rightarrow [0,1]$

1)  $i(0,y) = 1$

2)  $i(x,1) = 1$

$i(1,0) = 0$

$$x \leq y \Rightarrow \forall z : i(x,z) \geq i(y,z)$$

$$x \leq y \Rightarrow \forall z : i(z,x) \leq i(z,y)$$

a)  $\min\{1, -x+y, 1\}$  Schlesiericm

$i_1$  da  $x=0$

b)  $\min\{1, \frac{y}{1-x}\}$  da  $x \neq 0$  Bogunera

c)  $\max\{1 - \text{min}\{x,y\}\}$

Równość Hausdorff'a  $e: [0,1] \times [0,1] \rightarrow [0,1]$

1.  $e(0,1) = 0$

2.  $e(x,y) = e(y,x)$

3.  $e(x,x) = 1$

4.  $x \in u \subseteq z$

a)  $1 - [x-y]$  twierdzenie

~, ~, ~, ~

# Modelowanie rachunków niespotyczanych

Np. Po ułożowaniu pieniężnej kwoty w banku po roku ta kwota zmienia się o jakieś iloraz z przedziału  
[ $-10\ 000, 30\ 000]$

1. Kryterium Pewnisty

$$E_n(K^*) = \begin{cases} 1 & \text{gdy } 1 = \min_{\text{min } K}^* \\ 0 & \text{w. p.p.} \end{cases}$$

$\max_{\text{max } K}$

		Godzić	nie Godzić	Pewnista
oczyd	oczyd	10	-10	-10
	nie oczyd	-5	0	-5
				-5 nie!

2. Kryterium optymalny (zaklęty max)

$$E_n(K^*) = \max_{\alpha} K^* - \max_{\alpha} \min_{k \in K(\alpha)} K^*$$

no

o

no

Tall!

3. Kryterium Herwiga

$\alpha = [0,1]$  - wspólny kryterium optymalizmu

$$E_\alpha(K^*) = \begin{cases} 1 & \text{gdy } \alpha \cdot \max K^* + (1-\alpha) \cdot \min K^* \\ & - \max_{k \in K(\alpha)} (\alpha \cdot \max K^* + (1-\alpha) \cdot \min K^*) \end{cases}$$

w.p.f.

no

-10

Herwig  $\alpha = \frac{1}{2}$

0

-5

0

-1,5

0

Tall!

11. Zniana niepewność losowość

Kryterium Laplace'a

Jestli wie ma przedstaw, by sądzić  
i mądry, to uzda wartościę teoretyczek  
uwzględniającą zaświadczenie losowe:  
o rozkładzie równomiernym i  
olla faktycznej zmiennej losowej skojarzyc  
się mądrym modelowaniem prawdopodobieństwa.

### III. Zamiana kryteriów stratami

#### Kryterium założ


Każdy element  $u \in U(a, x)$  zaliczy od:

- wartość danych  $a \in A$
- podjętej decyzji  $x \in Q(a)$
- oddziaływania zewnętrznego  
 $b \in B(a, x)$  na realizację decyzji

$x \in Q(a)$  dającą wartość iż  
kryterium  $u(a, b, x) \in X(a, x)$

Gdyby decydując przed podjęciem  
decyzji znać by to podjęły  
decyzję  $x^*$  tzn:

$$u(a, b, x^*) = \max_u u(a, b, x)$$



Modele de zborocenii  
pry Gli'znevym

Rough Sets

gřeš, dобра апросимація